데이터 기반 K-뷰티 글로벌 진출 전략

국가별 Top 100 진입 가능성 예측 & B2B 솔루션

분석 기간: 2025년 11월 ~ 2026년 2월

1. 핵심 결과 요약

3개국	37,528건	0.849	62개
글로벌 시장 분석 US · PL · VN	수집 리뷰 총량 3개국 합산	최고 ROC-AUC 베트남 모델	학습 피처 수 LightGBM

핵심 산출물 요약
K-뷰티 제품 속성 정보를 입력하면 미국·폴란드·베트남 각 시장에서
베스트셀러(Top 100) 진입 확률을 시장 진입 점수(0~100점)로 제공하는 B2B 의사결정 지원 도구

1-1. 예측 모델 성능 (최종 — LightGBM)

최종 서비스 모델로 선정된 LightGBM의 국가별 최종 성능은 아래와 같다. 단, 비교 실험에서는 일부 지표에서 XGBoost가 우세한 구간도 확인되었다.

미국(US) 모델이 ROC-AUC 0.774로 가장 높고, 폴란드(PL) 모델은 재현율 0.933으로 베스트셀러 후보 탐지에 특히 유리하다.

국가	모델	임계값	ROC-AUC	PR-AUC	정밀도	재현율	F1
PL 폴란드 (PL)	LightGBM	0.20	0.636	0.269	0.246	0.933	0.389
US 미국 (US)	LightGBM	0.28	0.774	0.401	0.333	0.733	0.458
VN 베트남 (VN)	LightGBM	0.36	0.767	0.486	0.423	0.733	0.537

성능 해석
· 미국(US) 모델이 ROC-AUC 0.774로 가장 높으며, 정밀도(0.333)와 재현율(0.733)이 균형 잡혀 있다
· 폴란드(PL) 모델은 재현율 0.933으로 베스트셀러 후보 탐지율이 가장 높다
· 베트남(VN) 모델은 PR-AUC 0.486, 재현율 0.733으로 준수한 수준이며, 추가 데이터 확보 시 개선 여지가 있다.

1-2. 국가별 핵심 인사이트 (SHAP 분석 결과)

SHAP 분석을 통해 국가별 베스트셀러 진입에 영향을 미치는 주요 변수를 도출했다.

국가	가장 중요한 요인	비즈니스 시사점
US 미국	리뷰 평점(rating_weighted)	평점 관리가 진입의 선결 조건
VN 베트남	리뷰 수(review_count_log)	리뷰 수(인지도)가 진입 성과와 직결됨
PL 폴란드	기능성 성분 수 + 가격 순위	합리적 가격과 기능성 성분 조합이 핵심 변수

2. 연구 배경 및 문제 인식

2-1. 연구 배경

K-뷰티에 대한 글로벌 수요 확대와 함께 중소 화장품 기업들의 해외 수출 시도가 증가하고 있다.

국가별 선호 성분·제형·가격대가 상이함에도 이를 정량 분석한 근거 데이터가 부재하여, 기업은 현지 시장 특성을 파악하지 못한 채 진출 여부를 결정해야 하는 구조적 한계에 놓여 있다.

핵심 문제
① 정보 장벽: 국가별 베스트셀러 성분·제형·가격대 데이터 부재
② 마케팅 리스크: 현지 반응 미확인 상태 출시 → 재고·광고비 매몰 손실
③ 의사결정 공백: 진출 국가·제품 선정을 정량 근거 없이 경험에만 의존

2-2. 해결 방향

본 프로젝트는 아래 3가지 방향으로 문제를 해소했다.

① 데이터 수집: 미국·폴란드·베트남 이커머스 베스트셀러 Top 500 제품 및 리뷰 크롤링

② 예측 모델 구축: LightGBM 기반 국가별 Top 100 진입 확률 예측 모델 학습

③ 서비스화: 예측 확률을 Market Entry Score(0~100)로 변환, B2B 대시보드로 제공

3. 프로젝트 개요

3-1. 목표

제품 속성 정보를 입력하면 국가별 시장 진입 적합도를 정량 점수로 제공하는 B2B 의사결정 지원 플랫폼 구현을 목표로 한다.

3-2. 분석 대상 국가 및 플랫폼

국가	플랫폼	수집 제품 수	수집 리뷰 수	선정 이유
US 미국	Amazon US	500개	14,094건	세계 최대 뷰티 시장, 높은 기준
PL 폴란드	Amazon PL	500개	12,084건	유럽 대표 시장, 성분 민감 소비자
VN 베트남	Shopee VN	500개	11,350건	동남아 K-뷰티 수요 급증

3-3. 전체 프로세스 흐름

본 프로젝트는 아래 5단계로 구성되며, 각 단계의 산출물이 다음 단계의 입력값으로 연결된다.

프로젝트 수행 단계
① 데이터 수집 및 DB 적재 → 3개국 베스트셀러 제품 + 리뷰 크롤링, MySQL에 정규화 저장
② 전처리 및 텍스트 분석 → LLM(OpenAI)으로 비정형 텍스트를 성분·키워드 컬럼으로 정규화
③ 감성분석 및 VOC 분석 → 문장 단위 감성 분류 + 소비자 불만/칭찬 키워드 추출
④ 예측 모델링 → LightGBM으로 국가별 Top 100 진입 확률 예측
⑤ 서비스화 및 시각화 → Power BI 대시보드 + Dify 기반 RAG 챗봇 구현

4. 데이터 수집

4-1. 제품 정보 크롤링

미국(Amazon US)·폴란드(Amazon PL)·베트남(Shopee VN) 플랫폼별 뷰티 카테고리 베스트셀러 Top 500 제품 메타데이터를 크롤링으로 수집했다.

수집 기술 구성
· 페이지네이션 처리: 다음 페이지로 자동 이동하며 데이터 수집
· 대기 시간(Wait) 적용: 페이지 로딩이 끝날 때까지 기다린 뒤 수집 → 데이터 누락 방지
· 공통 스키마: 국가별 상이한 형식을 순위·가격·리뷰 수·상품명·URL 기준으로 통일
· 수집 실패 대응: 차단이나 로딩 오류 발생 시 자동으로 재시도

4-2. 리뷰 크롤링

제품별 소비자 리뷰를 수집했다. 리뷰 데이터는 이후 감성 분석 및 VOC 추출의 핵심 입력값으로 활용된다.

국가	수집 리뷰 수	수집 방식	특이 사항
PL 폴란드	12,084건	Amazon 리뷰 페이지	"다음" 버튼 클릭으로 페이지 이동
US 미국	14,094건	Amazon 리뷰 페이지	"전체 보기" 버튼 다중 대응
VN 베트남	11,350건	Shopee 리뷰 API	예외 처리로 중단 없는 수집 유지
합계	37,528건	—	저장 경로·수집량 로그 기록으로 재현 가능

리뷰 페이지의 버튼 구조가 국가·플랫폼별로 상이하여("다음"/"전체 보기" 등 다중 케이스 대응) 예외 처리를 적용했다. 수집 오류 발생 시에도 전체 프로세스가 중단되지 않도록 설계했으며, 저장 경로·수집량을 로그로 기록하여 재현 가능성을 확보했다.

5. 전처리 및 데이터베이스 적재

5-1. LLM 을 이용한 텍스트 전처리

수집된 제품 설명은 다국어·광고 문구가 혼재된 비정형 텍스트다. 모델 학습에 적합한 정형 피처로 변환하기 위해 LLM 기반 전처리 파이프라인을 구축했다.

OpenAI LLM을 활용하여 제품 설명 원문에서 성분·키워드를 JSON 스키마로 자동 추출했다. temperature=0으로 고정하여 출력 일관성을 확보했다.

LLM 전처리 방식
· 입력: 상품 설명 원문 (예: "NIDA 얼티밋 모이스처라이징 크림 센텔라 아시아티카...")
· 처리: 역할·규칙을 고정한 시스템 프롬프트로 JSON 형식의 결과를 출력
· temperature=0 설정 → 매번 동일한 결과 보장 (일관성 확보)
· 출력 ①: 성분 목록 (예: 센텔라 아시아티카, 나이아신아마이드, 히알루론산, 콜라겐)
· 출력 ②: 핵심 키워드 (예: 보습, 주름, 잔주름, 피부 탄력, 피부 재생)

추출된 성분·키워드는 이진 피처(0/1)로 인코딩하여 모델 입력 피처에 포함했다.

5-2. 최종 피처 구성

모델 학습에 사용된 피처는 총 62개로 아래와 같이 구성된다.

피처 구분	포함 항목	생성 방법
제품 기본 정보	가격, 리뷰 수, 별점, 랭킹 순위	크롤링 직접 수집
텍스트 기반	제형, 피부 타입, 효능, 성분 (원-핫)	LLM 전처리 후 인코딩
파생 변수	review_count_log (로그 변환 리뷰 수) rating_weighted (가중 평점)	수식 계산

5-3. 데이터베이스(DB) 적재 및 정합성 검증

전처리 결과를 MySQL에 적재했다.

DB 적재 검증 결과
· 상품 적재: 미국·폴란드·베트남 각 500개 + 국내(올리브영) 100개 = 총 1,600개 상품
· 리뷰 적재: 3개국 합산 37,528건
· 고아 리뷰 0건 → FK 수준 정합성 통과 (조인 안정성 확보)

6. 감성분석 및 VOC(소비자 의견) 분석

6-1. 감성분석 방법론

단일 리뷰 내에서 긍정·부정 감성이 혼재하는 경우가 빈번하다. 리뷰 전체를 단일 라벨로 분류하면 세부 감성 정보가 손실되므로, 문장 단위 분리 후 분석 방식을 적용했다.

감성분석 수행 단계
STEP 1. 리뷰를 문장 단위로 분리
STEP 2. 각 문장마다 감성 점수(0~1)와 라벨(긍정/부정) 예측
STEP 3. 점수가 높은 TOP-N 문장을 "근거 문장"으로 선정
STEP 4. 근거 문장들의 점수 합산 → 리뷰 전체 대표 라벨 결정
STEP 5. 점수를 긍정 비율로 정규화 → 제품 간 비교 가능

6-2. VOC(Voice of Customer) 분석

감성 극성만으로는 소비자 반응의 원인을 파악하기 어렵다. 근거 문장(TOP-N)에서 속성별 VOC 키워드를 추출하여 국가·카테고리별 집계 피처로 구축했다.

VOC 속성 카테고리	포함 키워드 예시	활용
보습	촉촉함, 수분, 건조함 해결	긍정 VOC 상위 속성
효능	주름 개선, 잡티, 피부 탄력	긍정 VOC 상위 속성
자극·트러블	트러블, 피부 자극, 알레르기	부정 VOC 주요 경고
향	향기, 무향, 인공향	소비자 선호도 파악
가격·가성비	가격 대비, 비싸다, 저렴함	폴란드 시장 핵심 변수
지속력	오래 가는, 금방 사라짐	제품 개선 방향 도출

7. 예측 모델링

7-1. 모델 설계 원칙

클래스 불균형 처리(scale_pos_weight)와 재현율 우선 평가를 핵심 설계 원칙으로 삼았다. 세부 적용 방법은 아래 7-2에서 서술한다.

7-2. 데이터 구성 및 라벨링

국가별 학습 데이터 500건 중 Top 100 진입(양성) 비율은 20%(100건)로 클래스 불균형이 존재한다.

정확도 단독 지표로는 음성 편향 모델이 고점수를 얻는 문제가 있어, 재현율(Recall)과 PR-AUC를 주요 평가 지표로 설정했다.

클래스 불균형 해결 방법
· scale_pos_weight 적용: 양성(Top100) 데이터에 더 큰 가중치 부여
· 평가 지표 보완: 단순 정확도 대신 재현율(Recall)과 PR-AUC를 우선 지표로 사용
· 재현율 우선 이유: 유망 후보 미탐 비용이 오탐 비용보다 크다는 비즈니스 판단에 근거

7-3. 모델 비교: XGBoost vs LightGBM

XGBoost와 LightGBM을 동일 피처·조건에서 비교한 결과, XGBoost는 PR-AUC 평균(0.480)과 베트남 ROC-AUC(0.849)에서 우세했다. 반면 LightGBM은 평균 재현율(0.800)이 더 높았고, 학습 속도와 메모리 효율 측면에서도 서비스 운영에 유리한 특성을 보였다. 이에 따라 본 프로젝트는 성능 지표와 운영 적합성을 종합 검토하여 LightGBM을 최종 서비스 모델로 채택했다.

비교 항목	XGBoost (후보)	LightGBM (최종 선정)
학습 전략	레벨별 성장	리프별 성장
학습 속도	보통	매우 빠름
재현율 (평균)	0.622	0.800

메모리 사용량	높음	낮음 (효율적)
PR-AUC (평균)	0.480	0.385
베트남 ROC-AUC	0.849	0.767
최종 역할	성능 비교 기준 모델	최종 서비스 채택 모델

XGBoost는 성능 검증 기준 모델로 함께 활용했다.

7-4. 주요 하이퍼파라미터 설계 의도

파라미터	설정값	설계 의도
n_estimators	800	복잡한 국가별 패턴을 충분히 학습하기 위한 트리 수
learning_rate	0.03	작은 값으로 세밀한 학습 → 과적합 방지
scale_pos_weight	자동 계산	클래스 불균형 직접 보정 (Top 100 탐지력 향상)
threshold	국가별 0.19~0.40	0.05~0.40 범위 탐색 후 재현율 ≥ 0.6 만족하는 최적값 선택
random_state	42	실험 재현성 확보

7-5. 예측 결과: 시장 진입 점수(Market Entry Score)

국가별 예측 확률의 절대값은 직접 비교가 어려워, 국가 내 백분위 기반으로 0~100점 상대 점수(Market Entry Score)로 변환했다.

Market Entry Score
· 정의: 동일 국가 내 제품 간 상대 경쟁력을 0~100점으로 표현
· 예시: 미국 85점 = 미국 시장 내 상위 15% 수준
· 활용: 국가 내 상대 순위 기반으로 동일 시장 내 진입 유력 제품 식별 지원
· 저장: product_predictions 테이블에 국가별 확률 + 점수 함께 적재

8. 성과 리포팅: Power BI 대시보드

8-1. 모델링 성능 대시보드

Power BI 대시보드를 통해 예측 결과와 감성 분석 결과를 시각화했다.

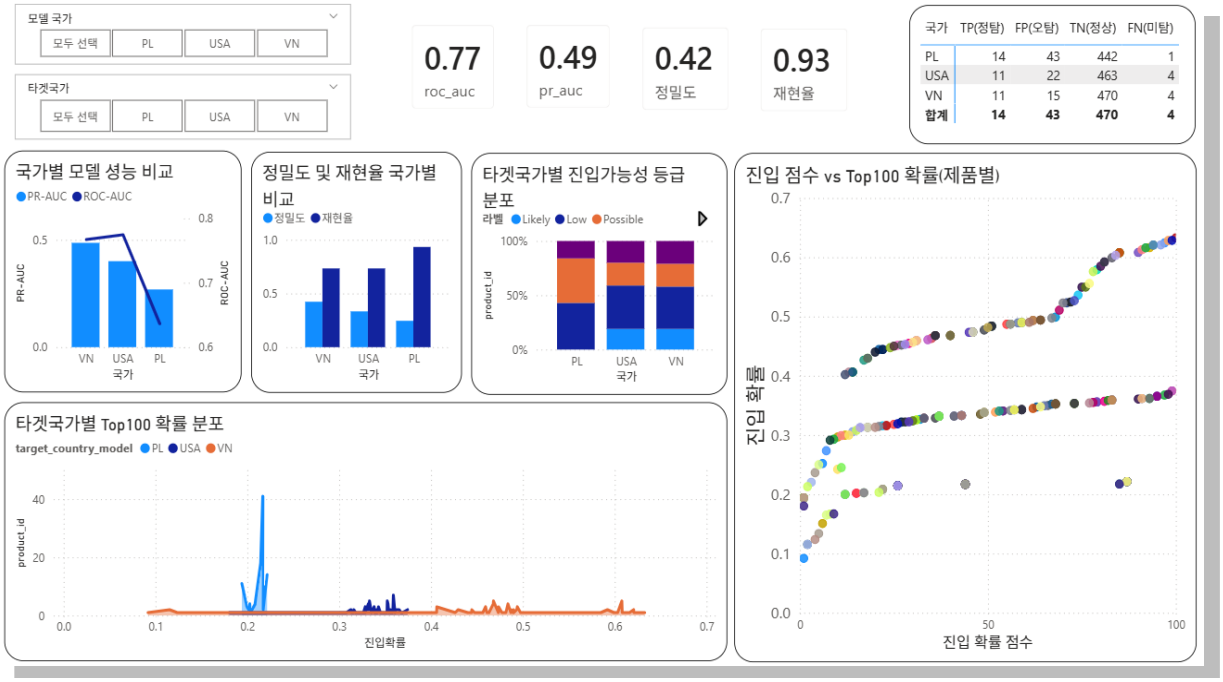

모델링 대시보드 구성
상단 KPI: ROC-AUC, PR-AUC, 정밀도, 재현율을 한 줄로 확인
오른쪽 표(혼동 행렬): 오탐(FP: 실제 음성을 양성으로 예측)과 미탐(FN: 실제 양성을 음성으로 예측) 수 표시
→ 오탐이 많으면 잘못된 제품에 리소스 낭비, 미탐이 많으면 유망 제품 기회 손실
산점도: 제품별 예측 결과 → 오른쪽 위에 위치할수록 유망 후보

8-2. 감성분석 대시보드

국가 선택 슬라이서를 변경하면 해당 시장의 분석 결과가 즉시 업데이트된다.

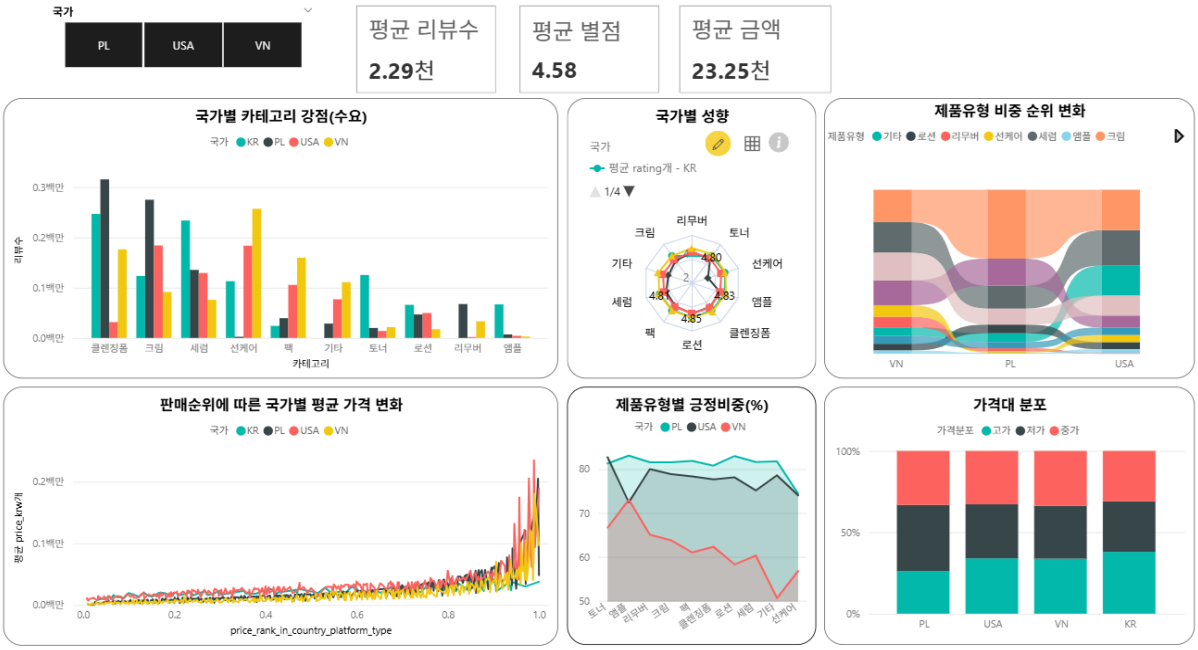

감성분석 대시보드 구성
상단 KPI: 선택 국가의 평균 리뷰 수, 평균 별점, 평균 가격 즉시 확인
가운데: 제품 유형별 관심도(수요 규모) + 긍정/부정 감성 비중 동시 시각화
수요 규모가 크고 부정 감성 비중이 낮은 카테고리를 진입 우선 타깃으로 식별
하단: 가격대 분포 + 랭킹 변화 → "어떤 가격대가 잘 팔리는가" 파악 가능

8-3. Dify 기반 RAG 챗봇

질문 유형	예시	챗봇 답변 방식
설명형	"부정 리뷰가 왜 나오나요?"	원인 구조화 후 대응 포인트 제시
수치형	"베트남 크림 부정 리뷰 수는?"	국가 확정 → 집계값 + 출처 파일 제시
로직 설명	"점수는 어떻게 계산했나요?"	백분위 변환 로직 단계별 설명

RAG 챗봇 구현 방식
· Dify 플랫폼 사용: 로우코드 방식으로 챗봇 흐름 설계
· 지식 베이스: 머신러닝 결과, 감성 분석 결과를 Markdown 파일로 저장
· 모델: GPT-5-mini (빠른 응답 속도 + 비용 효율)
· 사전 정의 응답 100개: 데이터에 없는 질문도 정해진 규칙으로 대응
· 지식 파일 임베딩 → 관련 내용 자동 검색 후 답변 생성

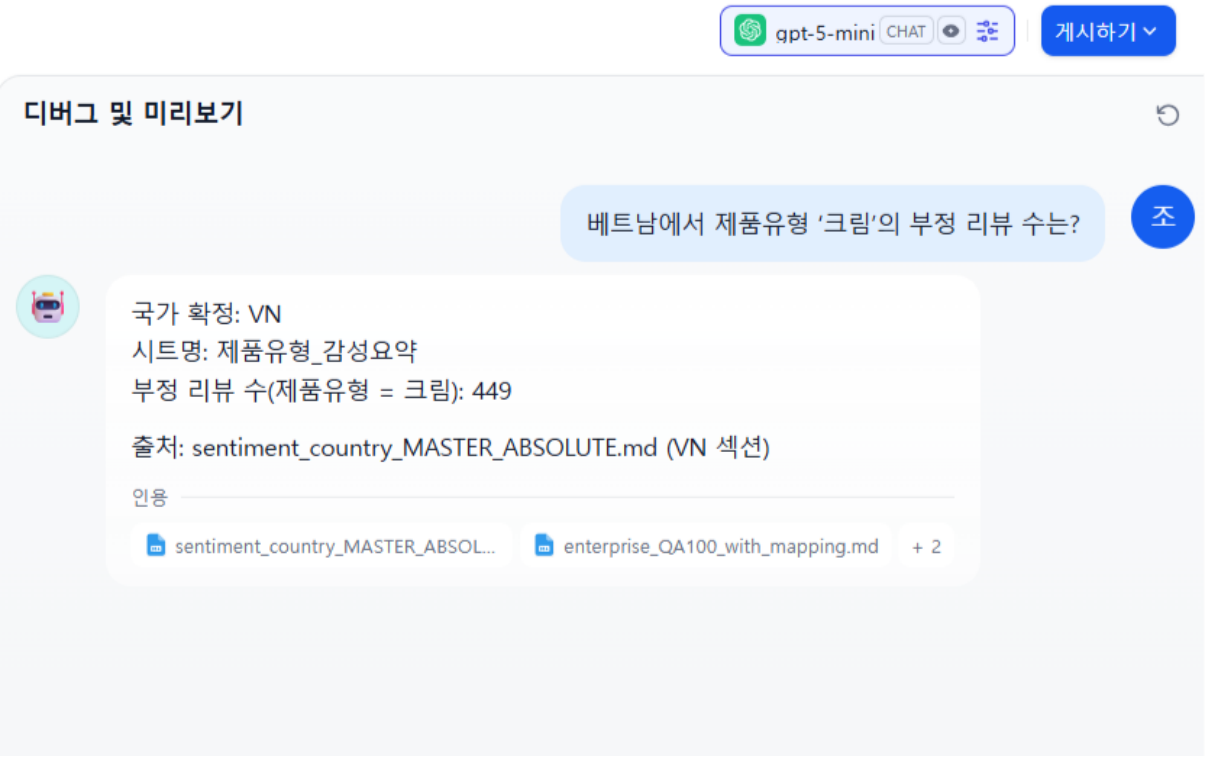

9. 시행착오 및 한계

9-1. 모델링 과정의 시행착오

정형 피처(가격, 성분, 리뷰 수 등) 중심 모델링 결과, 단기 수집 데이터만으로는 Top 100 진입 패턴을 충분히 설명하지 못함을 확인했다.

9-2. 데이터 구조적 한계

① 시계열(계절성) 데이터 부재

화장품 시장은 계절 변수의 영향이 크나, 프로젝트 기간 제약으로 4계절 시계열 데이터를 확보하지 못했다.

- → 보강 방향: Airflow 기반 연간 주기 크롤링으로 계절별 가중치 반영 모델링 구현

② 브랜드 파워(Brand Power) 피처 미활용

브랜드 인지도·마케팅 투자 등 외부 변수가 베스트셀러 진입에 실질적 영향을 미치나, 수치화 난이도로 인해 현재 피처셋에 반영하지 못했다.

- → 보강 방향: SNS 언급량·뉴스 API 결합으로 브랜드 지수(Brand Index) 정량 피처 개발

한계 극복 접근
이진 분류의 한계를 보완하기 위해 예측 확률을 국가 내 상대 점수(Market Entry Score)로 전환하여 의사결정 실용성을 높였다.

10. 결론 및 향후 계획

10-1. 달성 성과

달성 성과
① 실무형 E2E 파이프라인 완성
수집 → DB 적재 → LLM 전처리 → 감성분석 → 예측 모델 → 시각화 → RAG 챗봇
데이터 발생부터 서비스 제공까지 전 과정을 하나로 연결
② 조회형 서빙 구조
예측 결과를 DB에 적재 → 웹에서 조인/조회로 즉시 활용 가능
모델 결과가 곧바로 서비스 화면으로 연결되도록 DB적재
③ 비즈니스 대안 마련
이진 분류 한계 → Market Entry Score(시장 진입 적합도 지수)로 전환
기업이 "어느 나라에 먼저 진출할지" 상대 비교 가능

10-2. 향후 계획

계획	내용	기대 효과
데이터 밀도 강화	Airflow 주기적 스케줄링으로 4계절 시계열 데이터 확보	계절별 트렌드 반영 → 예측 정확도 향상
Brand Index 구축	SNS 언급량 + 뉴스 API 결합 브랜드 파워 수치화	외부 변수 포함 → 모델 설명력 강화
실시간 트렌드 대시보드	국가/카테고리별 급상승 키워드 실시간 감지	즉각적인 시장 변화 대응